

# **Statistique de la donnée**

---

## **Chapitre 4 : Modèle de régression linéaire multiple**

**Ali JAGHDAM**  
ESILV - 2020

## Exemple introductif

On cherche à modéliser la relation entre poids des bébés à naissance et l'âge, le poids et le statut tabagique de la mère durant la grossesse. On pose :

- $y$  = poids de naissance en grammes (bwt),
- $x_1$  = âge de la mère (age),
- $x_2$  = poids de la mère en kilos (weight),
- $x_3$  = statut tabagique de la mère pendant la grossesse (smoke) codée 1=oui et 0=non.

On suppose que cette relation est linéaire de la forme :

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$$

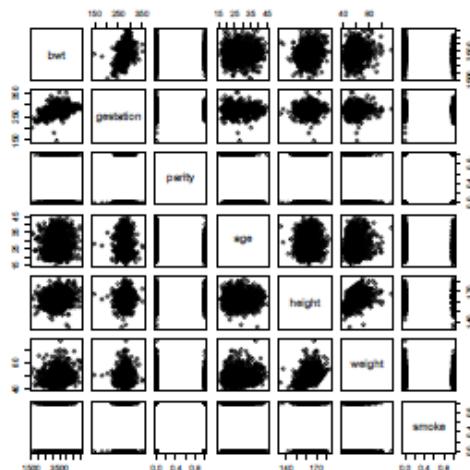
- On veut estimer cette relation avec un modèle de régression multiple.
- On utilise un échantillon de  $n = 1174$  naissances pour lesquelles le poids du bébé, l'âge, le poids et le statut tabagique de la mère, ont été mesurés.

# Exemple introductif

```
load("poids.RData")
print(data[1:5,c("bwt","age","weight","smoke")],digits=4)

##      bwt age weight smoke
## 1 3402  27   45.36     0
## 2 3203  33   61.23     0
## 3 3629  28   52.16     1
## 4 3062  23   56.70     1
## 5 3856  25   42.18     0
```

```
pairs(data) #diagrammes de dispersion
```



```
modele <- lm(bwt ~ age+weight+smoke,data=data)
modele$coefficients
```

```
## (Intercept)          age        weight       smoke
## 3050.56238    -0.91802     7.90266   -254.25425
```

## Le modèle

On cherche à modéliser la relation entre **plus de 2 variables quantitatives**.

Un **modèle de régression linéaire multiple** est de la forme suivante :

$$y = \beta_0 + \sum_{j=1}^p \beta_j x_j + \varepsilon \quad (1)$$

où :

- $y$  est la **variable à expliquer** (à valeurs dans  $\mathbb{R}$ ) ;
- $x_1, \dots, x_p$  sont les **variables explicatives** (à valeurs dans  $\mathbb{R}$ ) ;
- $\varepsilon$  est le **terme d'erreur aléatoire** du modèle ;
- $\beta_0, \beta_1, \dots, \beta_p$  sont les **paramètres à estimer**.

**Commentaires :**

- La désignation “**multiple**” fait référence au fait qu'il y a **plusieurs variables explicatives**  $x_j$  pour expliquer  $y$ .
- La désignation “**linéaire**” correspond au fait que le modèle (1) est linéaire.

## Le modèle

Pour  $n$  observations, on peut écrire le modèle de régression linéaire multiple sous la forme :

$$y_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij} + \varepsilon_i \quad \text{pour } i = 1, \dots, n. \quad (2)$$

Dans ce chapitre, on suppose que :

- $\varepsilon_i$  est une variable *aléatoire*, non observée,
- $x_{ij}$  est observé et *non aléatoire*,
- $y_i$  est observé et *aléatoire*.

On fait les trois **hypothèses additionnelles** suivantes :

(A1)  $\mathbb{E}[\varepsilon_i] = 0, \forall i = 1, \dots, n,$

ou de manière équivalente :

$$\mathbb{E}[y_i] = \beta_0 + \sum_{j=1}^p \beta_j x_{ij}, \quad \forall i = 1, \dots, n.$$

**Commentaire sur l'hypothèse (A1) :** elle indique que les erreurs sont centrées

(A2)  $\mathbb{V}(\varepsilon_i) = \sigma^2, \forall i = 1, \dots, n,$

ou de manière équivalente :

$$\mathbb{V}(y_i) = \sigma^2, \forall i = 1, \dots, n.$$

## Commentaires sur l'hypothèse (A2) :

- On parle d'hypothèse d'**homoscédasticité** ( $\simeq$  homogénéité des variances).
- Cette variance  $\sigma^2$  est un **paramètre du modèle qu'il faudra estimer**.

(A3)  $\text{Cov}(\varepsilon_i, \varepsilon_{i'}) = 0, \forall i \neq i'$

ou de manière équivalente :

$$\text{Cov}(y_i, y_{i'}) = 0, \forall i \neq i'.$$

## Commentaire sur l'hypothèse (A3) :

- Sous cette hypothèse, les termes d'erreur  $\varepsilon_i$  sont non corrélés.

## Le modèle

On peut écrire **matriciellement** le modèle (2) de la manière suivante :

$$\textcolor{teal}{Y} = \textcolor{blue}{X}\beta + \epsilon \quad (3)$$

où

$$\textcolor{teal}{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \textcolor{blue}{X} = \begin{pmatrix} 1 & x_{11} & \dots & x_{1p} \\ 1 & x_{21} & \dots & x_{2p} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n,1} & \dots & x_{np} \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}, \quad \text{et} \quad \epsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}.$$

- $\textcolor{teal}{Y}$  désigne le vecteur à expliquer de taille  $n$ ,
- $\textcolor{blue}{X}$  la matrice explicative de taille  $n \times (p + 1)$ ,
- $\epsilon$  le vecteur d'erreurs de taille  $n$ .

**Exercice :** Trouver  $X$  et  $Y$  pour les données sur les appartements.

Les **hypothèses** peuvent alors s'écrire sous forme matricielle :

$$(A1') \quad \mathbb{E}(\epsilon) = 0_n$$

ou de manière équivalente :

$$\mathbb{E}(Y) = X\beta \in \mathbb{R}^n.$$

$$(A2') \quad \mathbb{V}(\epsilon) = \sigma^2 I_n$$

ou de manière équivalente :

$$\mathbb{V}(Y) = \sigma^2 I_n.$$

Dans la suite de ce chapitre, on suppose que

$$n > (p + 1) \text{ et } \text{rang}(X) = p + 1$$

On a donc **plus d'observations que de variables** et il n'existe pas de liaison linéaire entre les variables explicatives  $x_j$  c'est à dire pas de multicolinéarité.

## Remarque.

Il est important de bien faire la différence entre

- l'expression  $\mathbb{E}(y_i) = \beta_0 + \sum_{j=1}^p \beta_j x_{ij}$  (qui désigne l'espérance d'une variable aléatoire scalaire), et l'expression  $\mathbb{E}(Y) = X\beta$  (qui désigne l'espérance d'une variable aléatoire vectorielle) : on obtient dans un cas un scalaire, dans l'autre cas un vecteur de  $\mathbb{R}^n$ .
- l'expression  $\mathbb{V}(y_i) = \sigma^2$  (qui désigne la variance d'une variable aléatoire scalaire), et l'expression  $\mathbb{V}(Y) = \sigma^2 I_n$  (qui désigne la covariance d'une variable aléatoire vectorielle) : on obtient dans un cas un scalaire ( $\sigma^2$ ), dans l'autre cas une matrice carrée ( $\sigma^2 I_n$ ) de dimension  $n \times n$ .

## Estimation des paramètres $\beta_1, \beta_2, \dots, \beta_p$ et $\sigma^2$

A partir de l'échantillon (aléatoire) de  $n$  observations

$$\{(x_{i1}, \dots, x_{ip}, y_i), i = 1, \dots, n\},$$

on veut **estimer** les paramètres

$$\beta_0, \beta_1, \dots, \beta_p \text{ et } \sigma^2.$$

- Pour estimer  $\beta = (\beta_0, \beta_1, \dots, \beta_p)$ , on peut utiliser la **méthode des moindres carrés** qui ne nécessite pas d'hypothèse supplémentaire sur la distribution de  $\varepsilon_i$ , contrairement à la **méthode du maximum de vraisemblance** qui est fondée sur la **normalité** de  $\varepsilon_i$ .
- La méthode des moindres carrés **ne fournit pas** un estimateur de  $\sigma^2$ .

## Estimation des paramètres $\beta_1, \beta_2, \dots, \beta_p$ et $\sigma^2$

### Estimation de $\beta$ par les moindres carrés

On cherche  $\hat{\beta} \in \mathbb{R}^{p+1}$  qui minimise la somme des erreurs quadratiques

$$\varepsilon_i^2 = (y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_p x_{ip})^2$$

On doit donc résoudre le problème d'optimisation suivant :

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} \sum_{i=1}^n [y_i - (\beta_0 + \sum_{j=1}^p \beta_j x_{ij})]^2. \quad (4)$$

Vocabulaire :

- $\hat{y}_i = \hat{\beta}_0 + \sum_{j=1}^p \hat{\beta}_j x_{ij}$  est appelé la valeur prédictive.
- $\hat{\varepsilon}_i = y_i - \hat{y}_i$  est appelé le résidu.

En notant  $x_i^T = (1, x_{i1}, \dots, x_{ip})$ , la valeur prédictive  $\hat{y}_i$  s'écrit

$$\hat{y}_i = x_i^T \hat{\beta}.$$

# Estimation des paramètres $\beta_1, \beta_2, \dots, \beta_p$ et $\sigma^2$

## Résolution du problème d'optimisation

Le problème d'optimisation est :

$$\min_{\beta \in \mathbb{R}^{p+1}} F(\beta),$$

avec

$$\begin{aligned} F(\beta) &= \sum_{i=1}^n [y_i - (\beta_0 + \sum_{j=1}^p \beta_j x_{ij})]^2 \\ &= (Y - X\beta)^T (Y - X\beta) \\ &= Y^T Y - 2Y^T X\beta + \beta^T X^T X\beta \end{aligned}$$

Le **minimum** est atteint pour

$$\frac{\partial F(\beta)}{\partial \beta} = 0.$$

**Rappels.** Soient  $a$  et  $x$  deux vecteurs de dimension  $K$ , et soit  $A$  une matrice de dimension  $K \times K$ . On a :

$$\frac{\partial a^T x}{\partial x} = \frac{\partial x^T a}{\partial x} = a \quad \text{et} \quad \frac{\partial x^T A x}{\partial x} = 2Ax \text{ si } A \text{ est symétrique.},$$

## Solution du problème d'optimisation

On en déduit après quelques manipulations :

$$\hat{\beta} = (X^T X)^{-1} X^T Y, \quad (5)$$

sous réserve que  $X^T X$  soit inversible.

## Commentaires

- Le minimum de  $F$  est égal à  $\sum_{i=1}^n \hat{\varepsilon}_i^2$ . Ce minimum est appelé la somme des carrés des résidus (SCR).
- La valeur prédictive  $\hat{y}_i$  estime  $\mathbb{E}[y_i] = \beta_0 + \sum_{j=1}^p \beta_j x_{ij}$  et non pas  $y_i$ . Une meilleure notation serait  $\widehat{\mathbb{E}[y_i]}$ .
- Aucune des hypothèses n'a été utilisée ici pour obtenir  $\hat{\beta}$ .

## Propriétés de $\hat{\beta}$

Sous les hypothèses **(A1')** et **(A2')**, on peut montrer que

- $E[\hat{\beta}] = \beta$ ,
- $V(\hat{\beta}) = \sigma^2(X^T X)^{-1}$

## Commentaires

- L'estimateur  $\hat{\beta}$  est **sans biais**.
- Il est aussi **de variance minimale** parmi tous les estimateurs linéaires par rapport à  $Y$  sans biais (propriété dite de Gauss-Markov).

## Estimation des paramètres $\beta_1, \beta_2, \dots, \beta_p$ et $\sigma^2$

### Estimation de $\sigma^2$

Le paramètre  $\sigma^2$  est défini par

$$\sigma^2 = \mathbb{V}(\varepsilon_i) = \mathbb{V}(y_i) = \mathbb{E} [(y_i - \mathbb{E}[y_i])^2].$$

En prenant  $\hat{y}_i = x_i^T \hat{\beta}$  comme estimateur de  $\mathbb{E}[y_i]$ , il apparaît naturel d'estimer  $\sigma^2$  par

$$s^2 = \frac{1}{n - (p + 1)} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{\sum_{i=1}^n (\hat{\varepsilon}_i)^2}{n - p - 1} = \frac{SCR}{n - p - 1}.$$

### Commentaires

- $s^2$  est un estimateur sans biais de  $\sigma^2$
- La perte de  $p + 1$  degrés de liberté dans l'expression de  $s^2$  est le "coût" de l'estimation de  $\beta_0, \beta_1, \dots, \beta_p$  nécessaire pour obtenir les  $\hat{y}_i$ .

## Sorties R des données poids de naissance

```
summary(modele)

##
## Call:
## lm(formula = bwt ~ age + weight + smoke, data = data)
##
## Residuals:
##    Min     1Q Median     3Q    Max 
## -1961   -308     11    309   1487 
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)    
## (Intercept) 3050.562   108.861   28.02 < 2e-16 ***
## age         -0.918      2.535   -0.36    0.72    
## weight       7.903      1.568    5.04  5.4e-07 ***
## smoke      -254.254    29.939   -8.49 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 499 on 1170 degrees of freedom
## Multiple R-squared:  0.081, Adjusted R-squared:  0.0786 
## F-statistic: 34.4 on 3 and 1170 DF,  p-value: <2e-16
```

## Tests d'hypothèses et intervalles pour les paramètres $\beta_j$

On veux maintenant tester la nullité des coefficients  $\beta_j$  du modèle de régression.

Pour faire ces tests, il est nécessaire de faire une **hypothèse supplémentaire** :

$$(A3)' \quad \epsilon \sim \mathcal{N}(0_n, \sigma^2 I_n)$$

ou de manière équivalente

$$Y \sim \mathcal{N}(X\beta, \sigma^2 I_n).$$

**Commentaire.** L'unique "nouveauté" ici est la **normalité**.

## Test de signification du modèle

Typiquement, on commence par tester :

$$\mathcal{H}_0 : \beta_1 = \dots = \beta_p = 0 \text{ contre } \mathcal{H}_1 : \exists j \in \{1, \dots, p\}, \beta_j \neq 0.$$

On utilise la **statistique** suivante :

$$F_n = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y}_n)^2 / p}{\sum_{i=1}^n (y_i - \hat{y}_i)^2 / (n - p - 1)} = \frac{SCE/p}{SCR/(n - p - 1)}$$

qui est distribuée **sous  $\mathcal{H}_0$**  selon une **loi de Fisher** à  $p$  et  $n - p - 1$  degrés de libertés. On **rejette  $\mathcal{H}_0$**  avec un risque  $0 \leq \alpha \leq 1$  si

$$F_n \geq f_{1-\alpha}(p, n - p - 1)$$

où  $f_{1-\alpha}(p, n - p - 1)$  est le fractile d'ordre  $1 - \alpha$  de la loi  $F(p, n - p - 1)$ .

# Tests d'hypothèses et intervalles pour les paramètres $\beta_j$

## Table d'analyse de la variance (ANOVA) :

Source de variation	Somme des carrés	ddl	carré moyen	F
régression (expliquée)	$SCE = \sum_{i=1}^n (\hat{y}_i - \bar{y}_n)^2$	p	$\frac{1}{p} \sum_{i=1}^n (\hat{y}_i - \bar{y}_n)^2$	$\frac{SCE/p}{SCR/(n-p-1)}$
Résiduelle	$SCR = \sum_{i=1}^n (y_i - \hat{y}_i)^2$	$n-(p+1)$	$\frac{1}{n-p-1} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	
Totale	$SCT = \sum_{i=1}^n (y_i - \bar{y}_n)^2$	n-1	$\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y}_n)^2$	

### Remarques :

- On retrouve la statistique dite de Fisher  $F_n$  qui permet de tester l'ajustement du modèle.
- On retrouve la propriété fondamentale  $SCT = SCE + SCR$  qui permet de mesurer l'ajustement du modèle par le coefficient de détermination

$$R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}.$$

- Le coefficient  $R^2$  donne la proportion de variabilité de  $y$  qui est expliquée par le modèle. Plus le  $R^2$  est proche de 1, meilleure est l'adéquation du modèle aux données.

## Tests d'hypothèses et intervalles pour les paramètres $\beta_j$

### Test de significativité d'un paramètre $\beta_j$

On désire maintenant tester :

$$\mathcal{H}_0 : \beta_j = 0 \quad \text{contre} \quad \mathcal{H}_1 : \beta_j \neq 0$$

Nouvelles propriétés pour les estimateurs  $\hat{\beta}_j$  et  $s^2$

Sous les hypothèses (A1')-(A3'), on a :

(a)  $\hat{\beta}_j \sim \mathcal{N}(\beta_j, \sigma^2 c_{jj})$

où  $c_{jj}$  est le terme  $(j+1, j+1)$  de la matrice  $(X^T X)^{-1}$

(b)  $\frac{(n-p-1)s^2}{\sigma^2} \sim \chi^2(n-p-1)$

(c)  $\hat{\beta}_j$  et  $s^2$  sont indépendants

Un rappel de probabilité

Si  $U \sim \mathcal{N}(0, 1)$ ,  $V \sim \chi^2(\nu)$  et  $U$  est indépendant de  $V$ , alors  $\frac{U}{\sqrt{\frac{V}{\nu}}} \sim T(\nu)$ .

## Tests d'hypothèses et intervalles pour les paramètres $\beta_j$

On déduit alors des propriétés (a)-(c) que

$$\frac{\frac{\hat{\beta}_j - \beta_j}{\sqrt{\sigma^2 c_{jj}}}}{\sqrt{\frac{(n-p-1)s^2}{n-p-1}}} = \frac{\hat{\beta}_j - \beta_j}{s\sqrt{c_{jj}}} \sim T(n-p-1).$$

On utilisera donc la **statistique** suivante :

$$T_n = \frac{\hat{\beta}_j - \beta_j}{s\sqrt{c_{jj}}},$$

qui est distribuée selon une loi de Student à  $n-p-1$  degrés de libertés.

## Test de $\mathcal{H}_0$ contre $\mathcal{H}_1$

Sous l'hypothèse  $\mathcal{H}_0$  : " $\beta_j = 0$ ", on a

$$T_n = \frac{\widehat{\beta}_j}{s\sqrt{c_{jj}}} \sim T(n - p - 1). \quad (6)$$

Pour une hypothèse alternative  $\mathcal{H}_1$  : " $\beta_j \neq 0$ " bilatérale, on rejette  $\mathcal{H}_0$  avec un risque  $0 \leq \alpha \leq 1$  si

$$|t| \geq t_{1-\alpha/2}(n - p - 1)$$

où  $t$  est la réalisation de  $T_n$  et  $t_{1-\alpha/2}(n - p - 1)$  est le fractile d'ordre  $1 - \alpha/2$  de la loi  $T(n - p - 1)$ .

## Remarques.

Pour réaliser ce test, on peut également :

- regarder la **p-valeur** aussi appelée niveau de signification du test : si  $p\text{-valeur} \leq \alpha$ , on rejette  $\mathcal{H}_0$ . Dans le cas d'un test bilatéral ( $\mathcal{H}_1$  : " $\beta_1 \neq 0$ "), on a :

$$p\text{-valeur} = \mathbb{P}(|T_n| > |t| / \mathcal{H}_0). \quad (7)$$

On **rejette  $\mathcal{H}_0$**  si  $p\text{-valeur} \leq \alpha$ .

- construire **l'intervalle de confiance** de  $\beta_j$  :

$$[\hat{\beta}_j \pm t_{1-\alpha/2}(n - p - 1)s\sqrt{c_{jj}}].$$

On **rejette  $\mathcal{H}_0$**  si 0 n'appartient pas à cet intervalle.

# Tests d'hypothèses et intervalles pour les paramètres $\beta_j$

Rejeter  $\mathcal{H}_0$  signifie :

- que le coefficient  $\beta_j$  est significativement non nul,
- que  $\beta_j$  s'interprète comme le taux d'accroissement moyen de  $y$  en fonction d'une variation de  $x_j$  lorsque tous les autres régresseurs  $x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_p$  restent fixés.

Exemple des données poids de naissance.

```
summary(modele)$coefficients

##                               Estimate Std. Error t value    Pr(>|t|)    
## (Intercept) 3050.56238   108.8612  28.0225 1.2569e-132
## age          -0.91802    2.5353 -0.3621 7.1734e-01  
## weight        7.90266    1.5675  5.0414 5.3511e-07  
## smoke        -254.25425   29.9388 -8.4925 6.0621e-17 

confint(modele)

##                   2.5 %    97.5 %    
## (Intercept) 2836.9775 3264.1473
## age          -5.8922   4.0562  
## weight        4.8271   10.9782 
## smoke        -312.9940 -195.5145
```

## Contribution jointe d'un ensemble de régresseurs

On peut maintenant tester la nullité de  $q \leq p$  paramètres :

$$\mathcal{H}_0 : "\beta_1 = \dots = \beta_q = 0" \quad \text{contre} \quad \mathcal{H}_1 : "\exists j \in \{1, \dots, q\}, \beta_j \neq 0".$$

Cela revient à comparer deux modèles :

- le modèle complet à  $p$  regresseurs (modèle 1) pour lequel on évalue la somme des carrés des résidus  $SCR_1$ ,
- le modèle réduit à  $p - q$  regresseurs (modèle 0) pour lequel on évalue la somme des carrés des résidus  $SCR_0$ .

On peut montrer que sous  $\mathcal{H}_0$  :

$$\frac{(SCR_0 - SCR_1)/q}{SCR_1/(n - p - 1)} \sim F(q, n - p - 1).$$

## Tests d'hypothèses et intervalles pour les paramètres $\beta_j$

La zone de rejet associée à cette statistique de test est donc :

$$\mathcal{R} = ]f_{1-\alpha}(q, n-p-1), +\infty[.$$

Rejeter  $\mathcal{H}_0$  signifie qu'au moins un des  $q$  coefficients est non nul.

Exemple des données poids de naissance.

```
modele0 <- lm(bwt ~ smoke, data=data)
modele1 <- lm(bwt ~ age+weight+smoke, data=data)
anova(modele0,modele1)

## Analysis of Variance Table
##
## Model 1: bwt ~ smoke
## Model 2: bwt ~ age + weight + smoke
##   Res.Df      RSS Df Sum of Sq    F  Pr(>F)
## 1    1172 297411671
## 2    1170 291055628  2    6356043 12.8 3.2e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

## Prévision d'une valeur ultérieure

On désire **prévoir** à l'aide du modèle la valeur de la variable  $y$  pour des observations futures  $(x_{1,0}, \dots, x_{p,0})$  des  $p$  variables explicatives.

Posons

$$x_0 = (1, x_{1,0}, \dots, x_{p,0})^T \in \mathbb{R}^{p+1}$$

D'après le modèle on a :

$$y_0 = x_0^T \beta + \varepsilon_0,$$

et la prédiction est :

$$\hat{y}_0 = \widehat{\mathbb{E}[y_0]} = x_0^T \hat{\beta}.$$

L'erreur de prédiction est définie par  $\hat{y}_0 - y_0$  et on peut montrer que sous les hypothèses du modèle (incluant l'hypothèse de normalité), on a :

$$\hat{y}_0 - y_0 \sim \mathcal{N} \left( 0, \sigma^2 \left( 1 + x_0^T (X^T X)^{-1} x_0 \right) \right). \quad (8)$$

## Prévision d'une valeur ultérieure

On en déduit que :

$$\frac{y_0 - \hat{y}_0}{\sigma \sqrt{1 + x_0^T (X^T X)^{-1} x_0}} \sim \mathcal{N}(0, 1).$$

On peut montrer que :

$$\frac{y_0 - \hat{y}_0}{s \sqrt{1 + x_0^T (X^T X)^{-1} x_0}} \sim T(n - p - 1).$$

On utilise ce résultat pour construire un **intervalle de prédition** pour  $y_0$ , c'est à dire l'intervalle  $[A, B]$  tel que

$$\mathbb{P}(A \leq y_0 \leq B) = 1 - \alpha.$$

Ici,  $y_0$  est une variable aléatoire et non pas un paramètre. L'intervalle de prédition est donc un **intervalle dans lequel une future observation  $y_0$  va tomber avec une certaine probabilité** (différent d'un intervalle de confiance).

## Prévision d'une valeur ultérieure

On en déduit l'intervalle de prédition pour  $y_0$  au niveau de confiance  $1 - \alpha$  suivant :

$$\left[ \hat{y}_0 \pm t_{1-\alpha/2} (n - p - 1) s \sqrt{1 + x_0^T (X^T X)^{-1} x_0} \right]$$

On peut aussi construire un intervalle de confiance de la valeur moyenne

$$\mathbb{E}[y_0] = x_0^T \beta,$$

qui est cette fois un paramètre. On va donc chercher l'intervalle aléatoire  $[A, B]$  tel que

$$\mathbb{P}(A \leq \mathbb{E}[y_0] \leq B) = 1 - \alpha.$$

## Prévision d'une valeur ultérieure

Pour construire cet intervalle, on montre que :

$$\hat{y}_0 \sim \mathcal{N} \left( x_0' \beta, \sigma^2 x_0^T (X^T X)^{-1} x_0 \right),$$
$$\frac{\hat{y}_0 - x_0^T \beta}{s \sqrt{x_0^T (X^T X)^{-1} x_0}} \sim T(n - p - 1).$$

On en déduit l'intervalle de confiance de  $\mathbb{E}[y_0] = x_0^T \beta$  suivant :

$$\left[ \hat{y}_0 \mp t_{1-\alpha/2}(n - p - 1) s \sqrt{x_0^T (X^T X)^{-1} x_0} \right].$$

Exemple des données poids de naissance.

```
#prevision de l'age du bebe d'une femme de 30 ans, 50 kg et fumeuse
predict(modele,data.frame(age=30,weight=50,smoke=1),interval="prediction")

##      fit     lwr     upr
## 1 3163.9 2183.8 4144

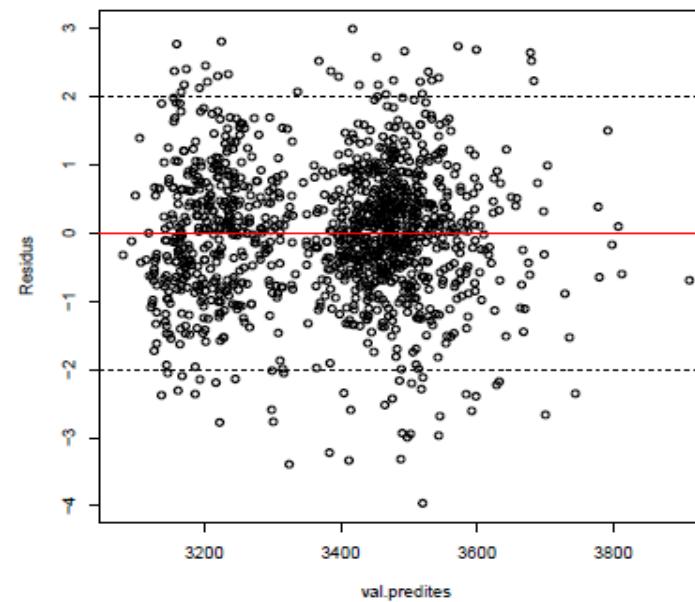
predict(modele,data.frame(age=30,weight=50,smoke=1),interval="confidence")

##      fit     lwr     upr
## 1 3163.9 3109.1 3218.7
```

# Analyse des résidus (Complément 1)

## Exemple des données poids de naissance.

```
#On calcule les residus studentisés  
residus=rstudent(modele)  
  
#On calcule les valeurs prédites  
val.predites <- predict(modele)  
  
#Graphique predictions-residus  
plot(val.predites ,residus, xlab="val.predites", ylab="Residus")  
abline(h=c(-2,0,2), lty=c(2,1,2),col=c(1,2,1))
```

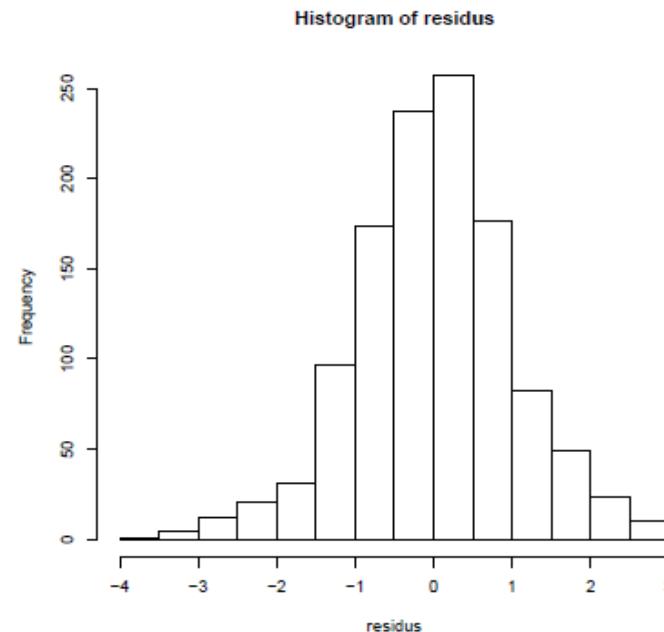


# Analyse des résidus (Complément 1)

```
#normalite des residus  
shapiro.test(residus)
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: residus  
## W = 0.993, p-value = 0.0000022
```

```
hist(residus)
```



## Sélection de variables (Complément 2)

Il s'agit maintenant de **sélectionner** parmi les  $p$  variables explicatives, les  $q \leq p$  variables qui donnent le "meilleur" modèle pour prédire  $y$ .

Il faut donc :

- **un critère** de qualité d'un modèle afin de comparer deux modèles n'ayant pas nécessairement le même nombre de variables explicatives.
- **une procédure** qui permet de choisir parmi tous les modèles, le meilleur au sens de ce critère. On parle de procédure de choix de modèle.

Un problème de complexité :

- Le nombre de modèles à considérer est  $\sum_{q=1}^p C_p^q = 2^p - 1$ . Ce nombre **croît exponentiellement avec  $p$** . Par exemple, si  $p = 30$ , on devrait considérer  $2^{30} = 10^9$  modèles...
- En pratique, on utilise donc des heuristiques dont les plus simples sont les **procédures pas à pas** ascendante ou descendante.

### Les critères $R^2$ et $R^2$ ajusté

- Le coefficient  $R^2 = 1 - \frac{SCR}{SCT}$ 
  - mesure l'ajustement du modèle aux données,
  - augmente lorsque le nombre de variables incluses dans le modèle augmente,
  - permet de **comparer** des modèles ayant le **même nombre de variables**.
- Le coefficient  $R_{\text{ajuste}}^2 = 1 - \frac{SCR/(n-p-1)}{SCT/(n-1)}$ 
  - estime le  $R_{\text{population}}^2 = 1 - \frac{\mathbb{V}(\varepsilon)}{\mathbb{V}(Y)} = 1 - \frac{\sigma^2}{\sigma_Y^2}$ ,
  - n'augmente pas forcément lorsque le nombre de variables introduites dans le modèle augmente,
  - permet de **comparer** des modèles ayant un **nombre de variables différent**.

## Sélection de variables (Complément 2)

### Les critères $AIC$ et $BIC$ .

Ce sont deux critères de vraisemblance pénalisées définis par :

- $AIC = -2\ln(\textcolor{teal}{L}) + 2k$  : Akaike Information Criterion
- $BIC = -2\ln(\textcolor{teal}{L}) + k\ln(n)$  : Bayesian Information Criterion

où  $\textcolor{teal}{L}$  est la vraisemblance maximisée et  $k$  est le nombre de paramètres libres du modèle.

En régression multiple :

- il y a  $q + 2$  paramètres  $\beta_0, \beta_1, \dots, \beta_q, \sigma$  et une équation donc  $k = q + 1$  paramètres libres.
- la vraisemblance est définie comme la densité conjointe des  $y_i$  et son expression est

$$L(\beta, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}(Y - X\beta)^T(Y - X\beta)\right)$$

Les estimateurs du maximum de vraisemblance sont  $\tilde{\beta} = (X^T X)^{-1} X^T Y$  et  $\tilde{\sigma}^2 = \frac{\text{SCR}}{n}$ . La vraisemblance maximisée est  $\textcolor{teal}{L} = L(\tilde{\beta}, \tilde{\sigma}^2)$  et on obtient :

$$-2\ln(\textcolor{teal}{L}) = n(\ln(2\pi\tilde{\sigma}^2) + 1)$$

Ecriture simplifiée en régression multiple.

$$AIC = n \ln(SCR) + 2k + cste$$

$$BIC = n \ln(SCR) + k \ln(n) + cste$$

Ces critères doivent être minimisés dans une procédure de choix de modèle.

### Procédure pas à pas ascendante (forward stepwise).

- On part du modèle nul sans variable.
- On effectue  $p$  régressions linéaires simples et on sélectionne le modèle qui minimise le critère AIC.
- On effectue  $p - 1$  régressions linéaires avec 2 variables explicatives et on sélectionne le modèle qui minimise le critère AIC.
- On recommence jusqu'à ce que le critère AIC ne diminue plus.

### Procédure pas à pas descendante (backward stepwise).

On part cette fois du modèle complet à  $p$  variables explicatives et on supprime pas à pas les variables. Le test d'arrêt et le critère sont les mêmes que pour la procédure ascendante.

# Sélection de variables (Complément 2)

## Exemple des données poids de naissance.

```
full <- lm(bwt ~ gestation + age + weight + smoke, data=data)
null <- lm(bwt ~ 1, data=data)
back <- step(full, direction="backward")

## Start: AIC=14379
## bwt ~ gestation + age + weight + smoke
##
##          Df Sum of Sq      RSS      AIC
## - age     1    60465 242763748 14377
## <none>           242703282 14379
## - weight   1   5352463 248055745 14402
## - smoke    1  14379595 257082877 14444
## - gestation 1  48352346 291055628 14590
##
## Step: AIC=14377
## bwt ~ gestation + weight + smoke
##
##          Df Sum of Sq      RSS      AIC
## <none>           242763748 14377
## - weight   1   5637978 248401726 14402
## - smoke    1  14556053 257319800 14443
## - gestation 1  48324498 291088245 14588

formula(back)

## bwt ~ gestation + weight + smoke
```

## Sélection de variables (Complément 2)

```
forw <- step(null, scope=list(lower=null,upper=full), direction="forward", trace = 1)

## Start: AIC=14683
## bwt ~ 1
##
##          Df Sum of Sq      RSS      AIC
## + gestation  1  52601391 264100599 14472
## + smoke     1  19290318 297411671 14611
## + weight    1   7699680 309002310 14656
## <none>           316701990 14683
## + age       1   230584 316471406 14684
##
## Step: AIC=14472
## bwt ~ gestation
##
##          Df Sum of Sq      RSS      AIC
## + smoke    1  15698873 248401726 14402
## + weight   1   6780798 257319800 14443
## + age      1   754996 263345603 14471
## <none>           264100599 14472
##
## Step: AIC=14402
## bwt ~ gestation + smoke
##
##          Df Sum of Sq      RSS      AIC
## + weight   1   5637978 242763748 14377
## <none>           248401726 14402
## + age     1   345981 248055745 14402
##
## Step: AIC=14377
## bwt ~ gestation + smoke + weight
##
##          Df Sum of Sq      RSS      AIC
## <none>           242763748 14377
## + age    1   60465 242703282 14379
```

## Sélection de variables (Complément 2)

```
formula(forw)

## bwt ~ gestation + smoke + weight

summary(lm(forw,data=data)) # idem forw

## 
## Call:
## lm(formula = forw, data = data)
## 
## Residuals:
##      Min       1Q   Median       3Q      Max 
## -1471.9  -305.0    -7.9   276.2  1455.9 
## 
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)    
## (Intercept) -499.702   246.393  -2.03   0.043 *  
## gestation     12.703    0.832   15.26  < 2e-16 *** 
## smoke        -229.004   27.341  -8.38  < 2e-16 *** 
## weight         7.386    1.417    5.21  2.2e-07 *** 
## --- 
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1 
## 
## Residual standard error: 456 on 1170 degrees of freedom
## Multiple R-squared:  0.233, Adjusted R-squared:  0.231 
## F-statistic: 119 on 3 and 1170 DF,  p-value: <2e-16
```