

Chapitre 2

Statistiques inférentielles


Ali JAGHDAM

ESILV - 2024

Partie 1: Estimation


UN EXEMPLE

Montant quotidien des dépôts en liquide dans la banque SOCIETE GENERALE.



UNE SOLUTION SIMPLE

Observer tous les dépôts




MAIS IMPOSSIBLE A METTRE EN ŒUVRE


car le nombre N d' observations est très grand, voire infini !

UNE AUTRE SOLUTION

On observe un échantillon, c.à.d. une partie de la population



INTERET DE LA STATISTIQUE DESCRIPTIVE



INTERET DE LA STATISTIQUE DESCRIPTIVE

Servir de base à la construction d'un **modèle théorique**

Pourquoi ?


Pour faire de la prévision:

Quelle quantité de monnaie acheter à la Banque de France en début de semaine?

Quelle quantité de liquide va-ton pouvoir faire transiter par la France ?.....

UN MODELE MATHEMATIQUE

Test d'ajustement :
On verra plus tard...




X = Montant quotidien des dépôts est une variable aléatoire

de loi Normale

de moyenne $E(X) = \mu$

de variance $V(X) = \sigma^2$



3 affirmations
à vérifier

Estimation

ESTIMATION DE LA MOYENNE μ

Comment avoir une idée sur la valeur de la moyenne μ ?



1) Prendre rendez-vous avec Irma la voyante

Problèmes: ça va me coûter cher. Puis-je lui faire confiance ?



2) Utiliser l'intuition et quelques notions de probabilités

Problème: je n'ai rien compris aux probas

C'est pas grave car on ne va plus s'amuser à jeter des dés ou tirer des cartes...

Avantage: je pourrai préciser la confiance à apporter à mon résultat

UNE METHODE INTUITIVE D'ESTIMATION DE LA MOYENNE

Pour estimer la moyenne μ inconnue de la population
on utilise la moyenne \bar{x} de l'échantillon.


Est-on sûr de faire mieux qu'Irma ?



UNE METHODE INTUITIVE D'ESTIMATION DE LA MOYENNE

On observe n dépôts x_1, \dots, x_n sur un échantillon et on en fait la moyenne \bar{x}
 \bar{x} va-t-elle être proche de μ inconnue?


Et si j'insiste
lourdement ?



Théorème fondamental:

Si X est une v.a. de moyenne μ et d'écart-type σ , alors la v.a. moyenne, notée \bar{X} , obtenue sur un échantillon de taille n tend vers une $N(\mu, \sigma/\sqrt{n})$

Prendre une décision à partir d'un échantillon, est-ce vraiment fiable ?



Fiabilité \longleftrightarrow Probabilité

Précision

Quelle est la probabilité que la moyenne inconnue μ se trouve pas trop loin de \bar{x} observée ?

Il y a $1-\alpha = 95$ chances sur 100 que l'intervalle $[\bar{x}-a ; \bar{x}+a]$ contienne μ

UN PEU..... DE PROBAS....

\bar{X} suit une loi $N(\mu, \sigma/\sqrt{n})$, donc $\sqrt{n}(\bar{X}-\mu)/\sigma$ suit une $N(0,1)$

Table

$$P[-u < \sqrt{n}(\bar{X}-\mu)/\sigma < u] = 1-\alpha = 0,95 \longrightarrow u = \text{environ } 2 \text{ (1,96)}$$

$$\iff P[-u\sigma/\sqrt{n} < \bar{X}-\mu < u\sigma/\sqrt{n}] = 1-\alpha$$

$$\iff P[-\bar{X}-u\sigma/\sqrt{n} < -\mu < -\bar{X}+u\sigma/\sqrt{n}] = 1-\alpha$$

$$\iff P[\bar{X}+u\sigma/\sqrt{n} > \mu > \bar{X}-u\sigma/\sqrt{n}] = 1-\alpha$$

$$\iff P[\bar{X}-u\sigma/\sqrt{n} < \mu < \bar{X}+u\sigma/\sqrt{n}] = 1-\alpha$$

Il y a $1-\alpha$ chances que la moyenne inconnue μ appartienne
à l'intervalle aléatoire $[\bar{X}-u\sigma/\sqrt{n}; \bar{X}+u\sigma/\sqrt{n}]$

UN PEU..... DE PROBAS.... FIN




Il y a 95 chances sur 100 que la moyenne inconnue μ appartienne à l'intervalle aléatoire $[\bar{X} - u\sigma/\sqrt{n}; \bar{X} + u\sigma/\sqrt{n}]$



Une observation aléatoire nous donne la valeur \bar{x} de \bar{X} .

$$\rightarrow [\bar{x} - u\sigma/\sqrt{n}; \bar{x} + u\sigma/\sqrt{n}]$$


Une autre observation nous aurait donné une autre valeur \bar{x} ,
..... et donc un autre intervalle qui ne contient pas forcément μ




Si on peut prendre une infinité d'échantillons, 95% des intervalles contiennent μ
On dira (pour simplifier) que la moyenne inconnue μ a 95 chances sur 100 d'appartenir à l'intervalle numérique $[\bar{x} - u\sigma/\sqrt{n}; \bar{x} + u\sigma/\sqrt{n}]$

Fiabilité et précision

l'intervalle $\left[\bar{x} - u\sigma/\sqrt{n}; \bar{x} + u\sigma/\sqrt{n} \right]$ a $1-\alpha$ chances de contenir μ


précision


fiabilité


$1-\alpha$ et u sont liés par la relation $P[-u < \sqrt{n}(\bar{X}-\mu)/\sigma < u] = 1-\alpha$

$$P[-u < N(0,1) < u] = 1-\alpha$$

Fiabilité augmente


 u augmente


Précision diminue



Pour quelles raisons utiliser la moyenne de l'échantillon pour estimer la moyenne de la population ?


- 1) Pour des raisons intuitives
- 2) Pour des raisons théoriques



On a une forte probabilité que l'observation soit dans cette zone

$$E(\bar{X}) = \mu \quad E(T) \neq \mu$$

\bar{X} est un estimateur sans biais



Plus la taille de l'échantillon grandit plus la variance diminue. Pour n infini, l'observation tombe forcément sur μ .


\bar{X} est un estimateur convergent

RESUME SUR L'ESTIMATION D'UNE MOYENNE

d'une population Normale de variance connue

- Pour estimer la moyenne d'une population, on utilise la moyenne de l'échantillon → Estimation ponctuelle
- Pour avoir une idée de la fiabilité et de la précision du résultat on utilise un intervalle de confiance $\left[\bar{x} - u\sigma/\sqrt{n}; \bar{x} + u\sigma/\sqrt{n} \right]$ → Estimation par intervalle de confiance

avec u défini par $P[-u < N(0,1) < u] = 1-\alpha$



- Détermination de la taille d'échantillon pour une précision et un coefficient de confiance donnés

On veut que l'intervalle soit de la forme $\bar{x} \pm \Delta$, donc $\Delta = u \sigma / \sqrt{n}$ et $n = (u\sigma/\Delta)^2$

ESTIMATION PONCTUELLE DE LA VARIANCE σ^2

1) Pour des raisons intuitives

Il est naturel d'estimer la variance d'une population,

par la variance $s_n^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$ de l'échantillon

2) Pour des raisons théoriques

On estime la variance d'une population par la variance corrigée $s_{n-1}^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$ de l'échantillon, notée aussi s^2 .

Pourquoi ?

$$E(S^2) = \sigma^2$$

S^2 est un estimateur sans biais de σ^2

$$V(S^2) \xrightarrow{n \rightarrow \infty} 0$$

S^2 est un estimateur convergent de σ^2

ESTIMATION PAR INTERVALLE DE CONFIANCE DE LA VARIANCE σ^2 D'UNE POPULATION NORMALE

$\frac{(n-1)S^2}{\sigma^2}$ suit une loi de χ^2 à $(n-1)$ d.d.l.

$$P\left[a < \frac{(n-1)S^2}{\sigma^2} < b\right] = 1 - \alpha \quad \xrightarrow{\text{Table}} \quad a \text{ et } b (> 0) \text{ pour } 1-\alpha \text{ donné}$$

$$P\left[\frac{a}{(n-1)S^2} < \frac{1}{\sigma^2} < \frac{b}{(n-1)S^2}\right] = 1 - \alpha$$

$$P\left[\frac{(n-1)S^2}{a} > \sigma^2 > \frac{(n-1)S^2}{b}\right] = 1 - \alpha$$

$$P\left[\frac{(n-1)S^2}{b} < \sigma^2 < \frac{(n-1)S^2}{a}\right] = 1 - \alpha$$

D'où un intervalle de confiance

$$\left[\frac{(n-1)s^2}{b}; \frac{(n-1)s^2}{a}\right]$$

RESUME SUR L'ESTIMATION D'UNE VARIANCE

- Pour estimer la variance σ^2 d'une population, on utilise la variance corrigée s^2 de l'échantillon  Estimation ponctuelle
- Pour avoir une idée de la fiabilité et de la précision du résultat on utilise un intervalle de confiance

$$\left[\frac{(n-1)s^2}{b}; \frac{(n-1)s^2}{a} \right]$$

 Estimation par intervalle de confiance

$$P\left[\chi_{(n-1)}^2 < a\right] = \alpha/2$$

avec a et b définis par

$$P\left[\chi_{(n-1)}^2 < b\right] = 1 - \alpha/2$$

ESTIMATION PONCTUELLE D'UNE PROPORTION

Dans la population il y a une proportion p d'individus possédant un certain caractère.

1) Pour des raisons intuitives

Il est naturel d'estimer la proportion p d'une population par la proportion f de l'échantillon

2) Pour des raisons théoriques

F , proportion d'échantillon, est une v.a. qui tend vers une loi $N\left(p, \sqrt{\frac{p(1-p)}{n}}\right)$

$$E(F) = p$$

F est un estimateur sans biais de p

$$V(F) = \frac{p(1-p)}{n} \xrightarrow{n \rightarrow \infty} 0$$

F est un estimateur convergent de p

INTERVALLE DE CONFIANCE D'UNE PROPORTION

F tend vers une $N\left(p, \sqrt{\frac{p(1-p)}{n}}\right)$, ou encore

$\sqrt{n} \frac{F-p}{\sqrt{p(1-p)}}$ est à peu près une $N(0,1)$ dès que $n > 100$ et $0,1 < p < 0,9$

$$P\left[-u < \sqrt{n} \frac{F-p}{\sqrt{p(1-p)}} < u\right] = 1 - \alpha \quad \xrightarrow{\text{Table}} \text{u pour } 1-\alpha \text{ donné}$$

$$P\left[-u\sqrt{\frac{p(1-p)}{n}} < F-p < u\sqrt{\frac{p(1-p)}{n}}\right] = 1 - \alpha$$

$$P\left[-F-u\sqrt{\frac{p(1-p)}{n}} < -p < -F+u\sqrt{\frac{p(1-p)}{n}}\right] = 1 - \alpha$$

$$P\left[F-u\sqrt{\frac{p(1-p)}{n}} < p < F+u\sqrt{\frac{p(1-p)}{n}}\right] = 1 - \alpha$$

p (dans les bornes de l'intervalle aléatoire) étant inconnu, il est approché par une estimation f , d'où un intervalle de confiance

$$\left[f - u\sqrt{\frac{f(1-f)}{n}} ; f + u\sqrt{\frac{f(1-f)}{n}} \right]$$

RESUME SUR L'ESTIMATION D'UNE PROPORTION

- Pour estimer la proportion p d'une population,
on utilise la proportion f de l'échantillon → Estimation ponctuelle
- Pour avoir une idée de la fiabilité et de la
précision du résultat on utilise un intervalle
de confiance → Estimation par
intervalle de confiance

$$\left[f - u \sqrt{\frac{f(1-f)}{n}} ; f + u \sqrt{\frac{f(1-f)}{n}} \right]$$

pour $n > 100$ et $0,1 < f < 0,9$
(sinon utiliser un abaque)

avec u défini par $P[-u < N(0,1) < u] = 1-\alpha$

- Détermination de la taille d'échantillon pour une précision et un coefficient de confiance donnés

On veut que l'intervalle soit de la forme $f \pm \Delta$, donc $\Delta = u \sqrt{\frac{f(1-f)}{n}}$
et $n = (u/\Delta)^2 f(1-f)$

ESTIMATION PONCTUELLE : UNE CONCLUSION

X de loi quelconque
de moyenne $E(X) = \mu$, de variance $V(X) = \sigma^2$



La moyenne \bar{X} de l'échantillon est une bonne estimation de la moyenne μ de la population
La variance corrigée s^2 de l'échantillon est une bonne estimation de la variance σ^2 de la population

Proportion p d'un caractère

La proportion f de l'échantillon est une bonne estimation de la proportion p de la population

INTERVALLE DE CONFIANCE D'UNE MOYENNE: EXTENSIONS

Pour obtenir un intervalle de confiance de la moyenne $\bar{x} \pm u\sigma/\sqrt{n}$ nous avons supposé (sans le dire) que

La taille d'échantillon est grande


La variance σ^2 est connue (ce qui en pratique est très rare)

Le taux de sondage n/N est faible ($<10\%$)

Que peut-on faire si ces conditions
ne sont pas respectées ?

INTERVALLE DE CONFIANCE D'UNE MOYENNE EXTENSIONS

	Conditions	Intervalle	u ou t défini par
σ^2 connu	Population Normale ou $n > 5$	$\bar{x} \pm u\sigma/\sqrt{n}$	$P[-u < N(0,1) < u] = 1 - \alpha$
σ^2 inconnu	Population Normale ou $n > 30$	$\bar{x} \pm us/\sqrt{n}$	$P[-u < T_{(n-1)} < u] = 1 - \alpha$



Loi de Student à $(n-1)$ d.d.l qui est approximativement $N(0,1)$ pour $n > 30$

- Dans ce tableau, on suppose que l'échantillon est prélevé avec remise, ou que l'échantillon est prélevé sans remise et le taux de sondage $n/N < 10\%$
- Dans le cas d'un échantillon prélevé sans remise, et un taux de sondage $n/N > 10\%$, on multiplie σ ou s par le facteur d'exhaustivité $\sqrt{\frac{N-n}{N-1}}$

Ce correctif doit aussi être apporté pour un intervalle de confiance d'une proportion

Partie 2: Test d'hypothèses

Population

caractère observé X , de moyenne μ ,
de variance σ^2

Un test consiste à

- Émettre une hypothèse, notée H_0 , appelée hypothèse nulle, sur un paramètre de X , sa loi...
- Proposer une hypothèse alternative, notée H_1
- Choisir une grandeur calculée à partir de l'échantillon, appelée **statistique**
- Construire une règle de décision
- Déterminer la zone de rejet de l'hypothèse H_0 en fonction d'un risque d'erreur α que l'on veut bien accepter
- Prendre une décision

LES RISQUES D'ERREUR DANS UN TEST

		La décision est	
		Accepter H_0	Rejeter H_0
La réalité est	H_0 vraie	Bonne décision	Mauvaise décision: Erreur α
	H_0 fausse	Mauvaise décision: Erreur β	Bonne décision

$$\alpha = P(\text{Rejeter } H_0 \text{ sachant que } H_0 \text{ est vraie})$$

$$\beta = P(\text{Accepter } H_0 \text{ sachant que } H_0 \text{ est fausse})$$

IMPORTANCE DU CHOIX DES HYPOTHESES

H_0 est l'hypothèse à laquelle on tient le plus, la plus vraisemblable...

→ Il est donc plus grave de la rejeter à tort que de l'accepter à tort

Pour construire le test on se fixe $\alpha = P(\text{Rejeter } H_0 \text{ sachant que } H_0 \text{ est vraie})$



Souvent l'utilisateur ne calcule pas $\beta = P(\text{Accepter } H_0 \text{ sachant que } H_0 \text{ est fausse})$

EXAMPLE: Les OGM sont-ils bons pour la santé?

Point de vue du consommateur

$H_0 = \text{les OGM ne sont pas bons}$

Point de vue de MONSANTO

$H_0 = \text{les OGM sont bons}$

Si β n'est pas calculé, le choix de H_0 n'est pas innocent

Test de comparaison d'une moyenne à une valeur donnée (variance connue)

Conditions d'application: σ connu. X suit une loi $N(\mu, \sigma)$, n quelconque
 X quelconque, $n > 5$ (AFNOR)

Hypothèses: $H_0 = \{\mu = \mu_0\}$ contre $H_1 = \{\mu < \mu_0\}$

Statistique: \bar{X} qui est un bon estimateur de la moyenne

Règle de décision:


Si H_0 est vraie, $\mu = \mu_0$

\bar{x} est une bonne estimation de μ ,
donc est proche de μ

Si H_1 est vraie, $\mu < \mu_0$

\bar{x} est une bonne estimation de μ ,
donc est proche de μ

Conclusion: Il existe μ_0-h tel que



$\bar{x} < \mu_0 - h \iff$ On rejette H_0


$\bar{x} > \mu_0 + h \iff$ On accepte H_0

Test de comparaison d'une moyenne à une valeur donnée (variance connue) Suite 1

Règle de décision:

$$\bar{x} < \mu_0 - h \iff \text{On rejette } H_0$$

$$\bar{x} > \mu_0 - h \iff \text{On accepte } H_0$$



Zone de rejet:

$$\alpha = P(\text{Rejeter } H_0 \text{ sachant que } H_0 \text{ est vraie}) \rightarrow \bar{X} \text{ suit une } N\left(\mu_0, \sigma/\sqrt{n}\right)$$

$$= P\left[\bar{X} < \mu_0 - h / \mu = \mu_0\right] = P\left[\bar{X} - \mu < \mu_0 - h - \mu / \mu = \mu_0\right]$$

$$= P\left[\sqrt{n}\left(\frac{\bar{X} - \mu}{\sigma}\right) < \sqrt{n}\left(\frac{\mu_0 - h - \mu}{\sigma}\right) / \mu = \mu_0\right]$$

$$= P\left[N(0,1) < -\sqrt{n} \frac{h}{\sigma}\right]$$


$$\alpha \text{ donné} \implies -\sqrt{n} \frac{h}{\sigma} \text{ et donc } h$$

Test de comparaison d'une moyenne à une valeur donnée (variance connue) Suite 2

Règle de décision:

$$\bar{x} < \mu_0 - h \Leftrightarrow \text{On rejette } H_0$$

$$\bar{x} > \mu_0 - h \Leftrightarrow \text{On accepte } H_0$$



Zone de rejet: permet de calculer h

Décision:

Si $\bar{x} < \mu_0 - h$, on rejette H_0 avec un risque α connu de se tromper

Si $\bar{x} > \mu_0 - h$, on accepte H_0 avec un risque β de se tromper

$\beta = P(\text{Accepter } H_0 \text{ sachant que } H_0 \text{ est fausse})$


\bar{X} suit une $N(\mu, \sigma/\sqrt{n})$

β est fonction de μ , et n'est pas toujours calculée par l'utilisateur. Si c'est le cas, plutôt que d'accepter H_0 , il vaut mieux conclure que l'échantillon observé ne permet pas de rejeter H_0 .

Test de comparaison d'une moyenne à une valeur donnée (variance connue) Suite 3 et fin


La règle de décision dépend de H_1

- $H_1 = \{ \mu < \mu_0 \}$




Règle: $\bar{x} < \mu_0 - h \iff$ On rejette H_0

- $H_1 = \{ \mu > \mu_0 \}$



Règle: $\bar{x} > \mu_0 + h \iff$ On rejette H_0

- $H_1 = \{ \mu \neq \mu_0 \}$



Règle: $\bar{x} < \mu_0 - h$ ou $\bar{x} > \mu_0 + h \iff$ On rejette H_0

Test de comparaison d'une moyenne à une valeur donnée (variance inconnue)

Conditions d'application: σ inconnu. X suit une loi $N(\mu, \sigma)$, n quelconque
 X quelconque, $n \geq 30$ (AFNOR)

Hypothèses: $H_0 = \{ \mu = \mu_0 \}$ contre $H_1 = \{ \mu < \mu_0 \}$
 $H_1 = \{ \mu > \mu_0 \}$
 $H_1 = \{ \mu \neq \mu_0 \}$

Statistique: $\sqrt{n} \frac{\bar{X} - \mu}{S}$ suit une $T_{(n-1)}$ (approximativement $N(0,1)$ si $n \geq 30$)

Règle de décision:

$$H_1 = \{ \mu < \mu_0 \} \quad \bar{x} < \mu_0 - h \iff \text{On rejette } H_0$$

$$H_1 = \{ \mu > \mu_0 \} \quad \bar{x} > \mu_0 + h \iff \text{On rejette } H_0$$

$$H_1 = \{ \mu \neq \mu_0 \} \quad \bar{x} < \mu_0 - h \text{ ou } \bar{x} > \mu_0 + h \iff \text{On rejette } H_0$$

Zone de rejet:

$$\alpha = P(\text{Rejeter } H_0 \text{ sachant que } H_0 \text{ est vraie}) = \dots \text{ d'où } h$$

Décision: en comparant \bar{x} à $\mu_0 - h$ ou (et) $\mu_0 + h$

Test de comparaison d'une proportion à une valeur donnée

Conditions d'application: tirage avec remise ou taux de sondage $n/N < 10\%$
 $n \geq 50$ et $np(1-p) \geq 9$ (AFNOR)

Hypothèses: $H_0 = \{ p = p_0 \}$ contre $H_1 = \{ p < p_0 \}$

$$H_1 = \{ p > p_0 \}$$

$$H_1 = \{ p \neq p_0 \}$$

Statistique: F bon estimateur de la proportion

$$F \text{ suit une } N\left(p, \sqrt{\frac{p(1-p)}{n}}\right)$$

Règle de décision:

$$H_1 = \{ p < p_0 \} \quad f < p_0 - h \iff \text{On rejette } H_0$$

$$H_1 = \{ p > p_0 \} \quad f > p_0 + h \iff \text{On rejette } H_0$$

$$H_1 = \{ p \neq p_0 \} \quad f < p_0 - h \text{ ou } f > p_0 + h \iff \text{On rejette } H_0$$

Zone de rejet:

$$\alpha = P(\text{Rejeter } H_0 \text{ sachant que } H_0 \text{ est vraie}) = \dots \text{ d'où}$$

Décision: en comparant f à $p_0 - h$ ou (et) $p_0 + h$

Test de comparaison de deux moyennes (variances connues)

Conditions d'application: σ_1, σ_2 connus .

X_1 suit une $N(\mu_1, \sigma_1)$, X_2 suit une $N(\mu_2, \sigma_2)$, n_i quelconques
 X_i quelconque, $n_i > 5$ (AFNOR)

Hypothèses: $H_0 = \{ \mu_1 = \mu_2 \}$ contre $H_1 = \{ \mu_1 < \mu_2 \}$

$$\begin{array}{ccc} \Leftrightarrow & H_1 = \{ \mu_1 > \mu_2 \} \\ \mu_1 - \mu_2 = 0 & H_1 = \{ \mu_1 \neq \mu_2 \} \end{array}$$

Statistique: Si H_0 vraie, $\bar{X}_1 - \bar{X}_2$ suit une $N(0, \sigma_d)$ avec $\sigma_d = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$

Règle de décision:

$$H_1 = \{ \mu_1 < \mu_2 \} \quad \bar{X}_1 - \bar{X}_2 < -h \iff \text{On rejette } H_0$$

$$H_1 = \{ \mu_1 > \mu_2 \} \quad \bar{X}_1 - \bar{X}_2 > h \iff \text{On rejette } H_0$$

$$H_1 = \{ \mu_1 \neq \mu_2 \} \quad \bar{X}_1 - \bar{X}_2 < -h \text{ ou } \bar{X}_1 - \bar{X}_2 > h \iff \text{On rejette } H_0$$

Zone de rejet:

$$\alpha = P(\text{Rejeter } H_0 \text{ sachant que } H_0 \text{ est vraie}) = \dots \text{ d'où } h$$

Décision: en comparant $\bar{X}_1 - \bar{X}_2$ à h ou (et) $-h$

Test de comparaison de deux moyennes (variances inconnues)

Conditions d'application: n_1 et $n_2 \geq 30$ (AFNOR)

Hypothèses: $H_0 = \{ \mu_1 = \mu_2 \}$ contre $H_1 = \{ \mu_1 < \mu_2 \}$

$$\begin{array}{ccc} \text{H}_1 & = & \{ \mu_1 < \mu_2 \} \\ \text{H}_1 & = & \{ \mu_1 \neq \mu_2 \} \\ \mu_1 - \mu_2 = 0 & & \end{array}$$

Statistique: Si H_0 vraie, $\bar{X}_1 - \bar{X}_2$ suit une $N(0, s_d)$ avec $s_d = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$

Règle de décision:

$$H_1 = \{ \mu_1 < \mu_2 \} \quad \bar{X}_1 - \bar{X}_2 < -h \iff \text{On rejette } H_0$$

$$H_1 = \{ \mu_1 > \mu_2 \} \quad \bar{X}_1 - \bar{X}_2 > h \iff \text{On rejette } H_0$$

$$H_1 = \{ \mu_1 \neq \mu_2 \} \quad \bar{X}_1 - \bar{X}_2 < -h \text{ ou } \bar{X}_1 - \bar{X}_2 > h \iff \text{On rejette } H_0$$

Zone de rejet:

$$\alpha = P(\text{Rejeter } H_0 \text{ sachant que } H_0 \text{ est vraie}) = \dots \text{ d'où } h$$

Décision: en comparant $\bar{X}_1 - \bar{X}_2$ à h ou (et) $-h$

Test de comparaison de deux proportions

Conditions d'application: tirage avec remise ou taux de sondage $n/N < 10\%$

$$n_1p, n_1(1-p), n_2p, n_2(1-p) \geq 5$$

Hypothèses: $H_0 = \{ p_1 = p_2 \}$ contre $H_1 = \{ p_1 < p_2 \}$



$$p_1 - p_2 = 0$$

$$H_1 = \{ p_1 > p_2 \}$$

$$H_1 = \{ p_1 \neq p_2 \}$$

Statistique: Si H_0 vraie, $F_1 - F_2$ suit une $N(0, \sigma_d)$ avec $\sigma_d = \sqrt{f_0(1-f_0)\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}$,
et $f_0 = \frac{n_1 f_1 + n_2 f_2}{n_1 + n_2}$ (estimation de $p = p_1 = p_2$)

Règle de décision:

$$H_1 = \{ p_1 < p_2 \} \quad f_1 - f_2 < -h \iff \text{On rejette } H_0$$

$$H_1 = \{ p_1 > p_2 \} \quad f_1 - f_2 > h \iff \text{On rejette } H_0$$

$$H_1 = \{ p_1 \neq p_2 \} \quad f_1 - f_2 < -h \text{ ou } f_1 - f_2 > h \iff \text{On rejette } H_0$$

Zone de rejet:

$$\alpha = P(\text{Rejeter } H_0 \text{ sachant que } H_0 \text{ est vraie}) = \dots \text{ d'où } h$$

Décision: en comparant $f_1 - f_2$ à h ou (et) $-h$


TEST D'AJUSTEMENT

UN EXEMPLE

On a observé pendant une longue période le montant hebdomadaire des dépôts en liquide dans la banque SG.

montant	[0 - 2000]	[2000 - 4000]	[4000 - 6000]	[6000 - 8000]	[8000 - 10000]	[10000 - 12000]
effectif	10	58	166	222	100	28

histogramme des dépôts



Le montant hebdomadaire des dépôts peut-il être considéré comme une loi Normale ?

Première étape: estimation des paramètres

Estimation ponctuelle:



$$\bar{x} = 6561$$


$$s = 2016$$

Deuxième étape: ajustement à une loi normale

Le montant hebdomadaire des dépôts est-il issu
d'une v.a. X de loi Normale ($\mu = 6561$; $\sigma = 2016$) ?




Observations



n_i = effectif observé dans la classe i
= aire de la surface de la classe i

$X \sim N(6561 ; 2016)$



$p_i = P(X \in \text{classe } i) = \int \phi(x) dx$
 np_i = effectif théorique dans la classe i
= aire de la surface de la classe i


Si les observations sont issues de la loi Normale (6561 ; 2016), les effectifs observés n_i dans la classe i doivent être très proches des effectifs théoriques np_i .

Comment mesurer globalement la proximité des deux graphiques ?

1) Une mesure intuitive

La proximité des 2 aires peut être mesurée par $n_i - np_i = Efo_i - Eft_i$

Plus cette quantité est faible (positive ou négative)
plus les aires sont proches



La proximité des 2 graphiques peut être mesurée par $\sum_i (Efo_i - Eft_i)^2$

! Cependant, si les écarts positifs compensent les écarts négatifs, cette quantité peut être très faible avec des valeurs très différentes dans les 2 graphiques !

2) Une mesure probabiliste

n_i est une observation d'une v.a.

Donc $\sum_i (Efo_i - Eft_i)^2$ est une observation d'une v.a. dont la loi n'est malheureusement pas connue. On utilise la quantité

$$D = \sum_i \frac{(Efo_i - Eft_i)^2}{Eft_i}$$

Nombre de classes
de la variable

Nombre de
paramètres estimés

qui suit une loi de χ^2 à $v = (k - r - 1)$ d.d.l.

Remarques importantes

Le nombre de classes et l'amplitude des classes n'a pas d'importance

L'utilisation de la loi du χ^2 n'est justifiée que si les effectifs théoriques de chacune des classes est supérieur ou égal à 5.

Si ce n'est pas le cas, il faut regrouper des classes contiguës afin d'augmenter les effectifs.

Le nombre de degrés de liberté de la loi du χ^2 dépend du nombre de classes après regroupement.

Résumé sur le test d'ajustement

Hypothèses: $H_0 = \{ \text{les observations sont issues d'une certaine loi} \}$

contre $H_1 = \{ \text{les observations ne sont pas issues de cette loi} \}$

Statistique: Si H_0 vraie, $D = \sum_i \frac{(Efo_i - Eft_i)^2}{Eft_i}$ est une χ^2 à $v = (k - r - 1)$ d.d.l.

Règle de décision:

$d > h \iff \text{On rejette } H_0$

$d < h \iff \text{l'échantillon observé ne permet pas de rejeter } H_0$

Zone de rejet:

$\alpha = P(\text{Rejeter } H_0 \text{ sachant que } H_0 \text{ est vraie}) = P\left(\chi_v^2 > h\right)$, d'où h

Décision: en comparant d à h

TEST D'INDEPENDANCE DE 2 VARIABLES

UN EXEMPLE

Montant des dépôts en liquide dans la banque Ibardinescroak en 2005

Catégories socio-professionnelles	X \ Y	Moins de 500 €	Entre 500 et 2000 €	Plus de 2000 €	Total
	Professions libérales	20	50	180	250
Fonctionnaires	50	30	20	100	
employés	230	10	10	250	
Total	300	90	210	600	

Y a-t-il un lien entre le montant des dépôts et la catégorie socio-professionnelle ?

	y_1	y_2	y_3	Total
x_1	20	50	180	250
x_2	50	30	20	100
x_3	230	10	10	250
Total	300	90	210	600

	...	y_j	...	Total
...
x_i	...	n_{ij}	...	$n_{i\cdot}$
...
Total	...	$n_{\cdot j}$...	n

Etudions la distribution de chacune des catégories professionnelles

	y_1	y_2	y_3	Total
x_1	$\frac{20}{250} = 8\%$	$\frac{50}{250} = 20\%$	$\frac{180}{250} = 72\%$	$\frac{250}{250} = 100\%$
x_2	$\frac{50}{100} = 50\%$	$\frac{30}{100} = 30\%$	$\frac{20}{100} = 20\%$	$\frac{100}{100} = 100\%$
x_3	$\frac{230}{250} = 92\%$	$\frac{10}{250} = 4\%$	$\frac{10}{250} = 4\%$	$\frac{250}{250} = 100\%$
Total	$\frac{300}{600} = 50\%$	$\frac{90}{600} = 15\%$	$\frac{210}{600} = 35\%$	$\frac{600}{600} = 100\%$



	...	y_j	...	Total
...
x_i	...	$n_{ij}/ n_{i\cdot}$...	$n_{i\cdot} / n_{i\cdot}$
...
Total	...	$n_{\cdot j}/ n$...	n/ n

Si la variable X était indépendante de la variable Y, les distributions de chaque modalité de X seraient identiques, **et identiques à celle du total**



$$n_{ij}/ n_{i\cdot} = n_{\cdot j}/ n \quad \text{pour tout } i \text{ et } j$$

$$n_{ij} = \frac{n_{i\cdot} \cdot n_{\cdot j}}{n}$$


Tableau initial

	...	y_j	...	Total
...
x_i	...	n_{ij}	...	$n_{i\cdot}$
...
Total	...	$n_{\cdot j}$...	n

Tableau lorsque X et Y sont indépendantes

	...	y_j	...	Total
...
x_i	...	$\frac{n_i \cdot n_{\cdot j}}{n}$...	$n_{i\cdot}$
...
Total	...	$n_{\cdot j}$...	n

Si les 2 variables X et Y sont indépendantes, les 2 tableaux doivent contenir des valeurs très proches:

n_{ij} doit être très proche de $\frac{n_i \cdot n_{\cdot j}}{n}$, pour tout i et j

Comment mesurer globalement la proximité des deux tableaux ?

1) Une mesure intuitive

La proximité de 2 cellules peut être mesurée par

Plus cette quantité est faible (positive ou négative)
plus les cellules sont proches

$$n_{ij} - \frac{n_i \cdot n_j}{n} = Efo_{ij} - Eft_{ij}$$

Effectif observé

Effectif théorique

La proximité des 2 tableaux peut être mesurée par $\sum_{i,j} (Efo_{ij} - Eft_{ij})^2$

! Cependant, si les écarts positifs compensent les écarts négatifs, cette quantité peut être très faible avec des valeurs très différentes dans les 2 tableaux !

2) Une mesure probabiliste

n_{ij} est une observation d'une v.a.

Donc $\sum_{i,j} (Efo_{ij} - Eft_{ij})^2$ est une observation d'une v.a. dont la loi n'est malheureusement pas connue. On utilise la quantité

$$D = \sum_{i,j} \frac{(Efo_{ij} - Eft_{ij})^2}{Eft_{ij}}$$

Nombre de modalités de la variable en ligne

Nombre de modalités de la variable en colonne

qui suit une loi de χ^2 à $v = (\ell-1)(c-1)$ d.d.l.

Remarques importantes

L'utilisation de la loi du χ^2 n'est justifiée que si les effectifs théoriques de chacune des cellules est supérieur ou égal à 5.

Si ce n'est pas le cas, il faut regrouper des modalités d'une des 2 variables afin d'augmenter les effectifs.

Le nombre de degrés de liberté de la loi du χ^2 dépend du nombre de modalités des 2 variables après regroupement.

Résumé sur le test d'indépendance de deux variables

Hypothèses: $H_0 = \{ \text{les 2 variables } X \text{ et } Y \text{ sont indépendantes} \}$

contre $H_1 = \{ \text{les 2 variables } X \text{ et } Y \text{ sont dépendantes} \}$

Statistique: Si H_0 vraie, $D = \sum_{i,j} \frac{(Efo_{ij} - Eft_{ij})^2}{Eft_{ij}}$ est une χ^2 à $v = (\ell-1)(c-1)$ d.d.l.

Règle de décision:

$d > h \iff \text{On rejette } H_0$

$d < h \iff \text{l'échantillon observé ne permet pas de rejeter } H_0$

Zone de rejet:

$\alpha = P(\text{Rejeter } H_0 \text{ sachant que } H_0 \text{ est vraie}) = P\left(\chi_v^2 > h\right)$, d'où h

Décision: en comparant d à h